

Pitch di progetto: Basi di Dati II

Data Warehouse: la corsa allo spazio (1957-2020)

Tipologia scelta: Progetto Data Warehouse classico

Stack: PostgreSQL, Kettle (Pentaho Data Integration), Pentaho Schema Workbench, Mondrian su Pentaho Server, Saiku Analytics (oppure JPivot) come front-end.

1. In sintesi

Costruire un data mart sulle missioni di lancio spaziale mondiali dal 1957 al 2020, integrando due dataset pubblici eterogenei, e pubblicare un cubo OLAP navigabile che permetta di analizzare **affidabilità, costi e cadenza dei lanci** lungo le dimensioni tempo, razzo, agenzia e sito di lancio.

2. Perché questo dominio

Il settore ha attraversato una trasformazione profonda, interamente contenuta nell'arco coperto dai dati: dal monopolio delle agenzie statali della Guerra Fredda al mercato dominato da operatori privati, con un raddoppio della cadenza di lancio a partire dal 2016 trainato soprattutto da SpaceX. Questo rende le analisi temporali significative.

Le interrogazioni supportate dal cubo hanno inoltre applicazioni concrete:

- **Assicurazioni sui lanci:** stima del rischio a partire dallo storico di affidabilità per razzo e agenzia.
- **Analisi di investimento:** confronto tra operatori pubblici e privati per cadenza, costi ed esiti.
- **Valutazione delle agenzie nazionali:** costo per lancio riuscito, nel tempo e per paese.

3. Le fonti dati

Fonte	Contenuto	Licenza
All Space Missions from 1957 (Kaggle, da Next Spaceflight)	4.324 righe, una per missione: azienda, luogo, data, dettaglio del lancio, nome e stato del razzo, costo, esito. Dal 1957 ad agosto 2020	Pubblica, scaricabile in CSV
Astronaut Database (Stavnychuk & Corlett, McGill University, DOI 10.17632/86tsnnbv2w.1)	1.277 righe, una per coppia astronauta-missione: anagrafica, nazionalità, agenzia, titolo e anno della missione, navette di andata e rientro, durata della missione e delle EVA. Fino a gennaio 2020	Mendeley Data, pubblica

Le due fonti hanno copertura temporale allineata (entrambe si fermano al 2020). Della stessa fonte originaria esiste uno [snapshot esteso ad agosto 2022](#) su Maven Analytics: richiede registrazione, ma resta un'opzione per coprire gli ultimi due anni.

La collegabilità è stata verificata sui dati: il nome della missione, estratto dal campo *Detail* dei lanci e normalizzato, aggancia il 72% delle righe del dataset astronauti, per 192 lanci con equipaggio identificati. Il residuo sono soggiorni su stazioni spaziali (Salyut, Mir, ISS), dove il titolo indica la stazione o l'expedition anziché un lancio.

Due fonti eterogenee soddisfano il criterio di integrazione tra sorgenti caratteristico di una DW e permettono di trattare concretamente la riconciliazione. Se servissero volumi maggiori o coperture mancanti, i dati reali possono essere affiancati da dati sintetici.

4. Struttura del data mart

Fatto: Lancio

Un evento primario corrisponde a una missione di lancio.

Misure

Misura	Tipo
Costo del lancio	grezza
Esito (successo / fallimento)	grezza, base per i tassi di successo calcolati a query-time
Conteggio missioni	implicita (COUNT)
Numero di astronauti a bordo	grezza, dalla seconda fonte
Giorni dall'ultimo lancio della stessa azienda	derivata in ETL
Numero progressivo di lancio dell'azienda	derivata in ETL

Le ultime due sono precalcolate in ETL perché richiedono un ordinamento dei lanci e un confronto tra righe consecutive; le altre restano grezze, aggregate a query-time. La suddivisione potrebbe cambiare dopo un'analisi più approfondita.

Dimensioni e gerarchie

Dimensione	Gerarchia
Tempo	Giorno → Mese → Trimestre → Anno → Decade/Era
Razzo	Razzo → Famiglia → Produttore; Razzo → Fascia di costo
Azienda/Agenzia	Azienda → Paese di origine → Continente
Sito di lancio	Sito → Paese ospitante → Continente
Astronauta	Astronauta → Agenzia → Paese

Il progetto prevede un solo fatto: la partecipazione degli astronauti non ha una dinamica temporale distinta da quella del lancio, quindi Astronauta ha più senso come dimensione. Anche questa scelta è da confermare con un'analisi più approfondita.

Schema e architettura

Schema a stella, con architettura a due livelli: sorgenti → ETL → data mart → cubo OLAP pubblicato.

5. Interrogazioni previste

Interrogazione	Operazioni OLAP
Tasso di successo dei lanci per decade	roll-up su Tempo
Confronto tra agenzie in una decade specifica	slice su Tempo
Tasso di successo per fascia di costo del razzo	dice su Fascia di costo × Tempo
Siti di lancio più usati da una data agenzia	dice su Sito × Azienda
Evoluzione della cadenza di lancio, pubblico vs privato	drill-down su Tempo, dice su Azienda

6. Copertura dei requisiti minimi

Requisito	Come viene soddisfatto
Uno o più dataset pubblici, consolidati e storicizzati	Due dataset pubblici, dati storici 1957-2020, nessun contesto OLTP necessario
Uso di un tool dedicato	Suite Pentaho: PDI/Kettle, Schema Workbench, Mondrian, Pentaho Server
Schema dimensionale (preferibilmente a stella): 1 fatto + almeno 2 dimensioni	Schema a stella con fatto Lancio e 5 dimensioni (Tempo, Razzo, Azienda, Sito, Astronauta)
Processo ETL completo con Kettle	Estrazione dai due CSV; pulizia del campo location (separazione sito/paese) e normalizzazione dei nomi agenzia tra le fonti; trasformazione con calcolo delle misure derivate; caricamento fisico nello schema a stella su PostgreSQL
Interrogazioni OLAP: drill-down, roll-up, slice, dice	Coperte dalle interrogazioni della sezione 5
Pubblicazione dello schema/cubo su server Pentaho, navigabile	Schema Mondrian pubblicato tramite Schema Workbench sul Pentaho Server, navigabile da Saiku Analytics

7. Considerazioni su scala e utilità

I volumi in gioco sono quelli tipici di un progetto accademico: poche migliaia di record, senza aggiornamento continuo. In un contesto reale una scala del genere non richiederebbe di per sé un'architettura di data warehousing. Il progetto riproduce le tecniche di modellazione dimensionale, integrazione di fonti, ETL e analisi OLAP su un caso di dimensioni ridotte. Dove servisse più materiale su cui lavorare, i dati reali possono essere estesi con dati sintetici.